

C 题建模总思路

目录

1 一、总体路线	4
2 二、数据清洗	4
3 已确认规则	5
3.1 规则 DC-01: 孕周格式统一	5
3.2 规则 DC-02: 重复检测分层处理	6
3.3 规则 DC-03: 首次达到 4% 的删失区间	6
3.4 规则 DC-04: 缺失值分类处理	6
4 三、第一问解答	7
4.1 1. 数据特征分析	7
4.2 2. 数据预处理方案	7
4.3 3. 模型选取及缘由	8
4.4 4. 模型及其参数介绍	8
4.5 5. 模型训练	9
4.6 6. 模型评分方式	9
4.7 7. 数值结果分析	10
4.8 8. 结论解释与边界	10
4.9 9. 补充	11
5 四、第二问解答	11
5.1 1. 数据特征分析	11
5.2 2. 问题分析	11
5.3 3. 指标定义	12

5.4	4. 模型与算法组件及选取缘由	12
5.5	5. 整体路线/算法结构	13
5.6	6. 训练方案	14
5.6.1	6.1 第一次训练：XGBoost-AFT 删失建模	14
5.6.2	6.2 第二次训练：全局 Optimal Binning 确定 BMI 组数与切点	15
5.6.3	6.3 第三次训练：最优推荐时间与安全裕量校准	15
5.7	7. 验证方案	16
5.8	8. 结论对比	16
5.9	9. 最终结果	17
5.10	10. 补充	17
6	五、第三问解答	17
6.1	1. 数据特征分析	17
6.2	2. 问题分析	18
6.3	3. 指标定义	18
6.3.1	3.1 维持定义	18
6.3.2	3.2 新增定义	18
6.3.3	3.3 变更定义	19
6.4	4. 模型与算法组件及选取缘由	19
6.5	5. 整体路线/算法结构	20
6.6	6. 训练方案	20
6.6.1	6.1 多因素达标概率训练	20
6.6.2	6.2 BMI 分组结构训练	20
6.6.3	6.3 推荐时点与部署政策训练	21
6.7	7. 验证方案	21
6.8	8. 结论对比	21
6.9	9. 最终结果	21
6.10	10. 补充	22
7	六、第四问解答	22
7.1	1. 数据特征分析	22
7.2	2. 问题分析	23

7.3	3. 指标定义	23
7.3.1	3.1 维持定义	23
7.3.2	3.2 新增定义	23
7.3.3	3.3 变更定义	24
7.4	4. 模型与算法组件及选取缘由	24
7.5	5. 整体路线/算法结构	25
7.6	6. 训练方案	25
7.6.1	6.1 多标签概率模型训练	25
7.6.2	6.2 概率校准与阈值训练	26
7.6.3	6.3 复测与最终分流规则训练	26
7.7	7. 验证方案	26
7.8	8. 结论对比	26
7.9	9. 最终结果	27
7.10	10. 补充	27
8	七、补充验证与最终诊断	27
8.1	1. 全部可行组数的嵌套验证	27
8.2	2. 患者级筛查三分流	28
8.3	3. 推荐时点策略敏感性	28
8.4	4. 主混合模型诊断	28

C 题总思路表

用途：作为论文写作底稿，记录最终采用的数据处理、模型、训练、验证和结论口径。

1 一、总体路线

阶段	核心任务	当前状态
1. 数据清洗	修正数据格式、处理重复检测、删失信息、缺失值及异常字段	完善中
2. 数据结构构造	分别形成纵向记录数据和患者级首次达标数据	已完成
3. 模型构建	关系模型、首次达标时间模型及多因素模型	已完成
4. BMI 分组与时点优化	搜索分组切点和各组推荐检测孕周	已完成
5. 验证与稳健性	嵌套验证、Bootstrap、误差敏感性和泄漏审计	已完成
6. 最终建议	汇总结论、适用范围和限制	已完成

2 二、数据清洗

编号	数据问题	当前处理方案	处理对象/阶段	处理理由	状态
1	同一孕妇存在多次检测，并存在短期内多次检测。男胎 1082 条检测记录对应 267 名孕妇；女胎 605 条检测记录对应 147 名孕妇。	问题 1 保留全部纵向检测记录，以孕妇随机截距处理同一孕妇记录间的关联性；问题 2、3 按孕妇转换为一条患者级记录。同一孕妇同一孕周的重复 Y 浓度取中位数，不同孕周记录按时间排序。训练、验证、测试划分及 Bootstrap 均以孕妇为单位。	重复检测、数据划分与建模单位	既保留问题 1 需要的纵向变化信息，又避免重复计权、伪独立和同一孕妇跨训练集与测试集造成的信息泄漏。	已确认
2	原始孕周采用类似 12w+3 的字符串格式，不能直接用于数值计算。	将 w+d 转换为十进制周：w+d/7。例如 12w+3=12+3/7=12.4286 周。	男胎、女胎全部检测记录	统一孕周量纲，便于排序、计算时间间隔、构造删失区间及模型训练。	已确认

编号	数据问题	当前处理方案	处理对象/阶段	处理理由	状态
3	检测时间不能精确确定 Y 染色体浓度首次达到 4% 的真实时间，存在左删失、区间删失和右删失。	同一孕妇同一孕周的重复 Y 浓度取中位数并按孕周排序。第一次检测已经达到 4% 时构造左删失区间 $[0,U]$ ；前一次未达标、后一次达标时构造区间删失 $[L,U]$ ；所有检测均未达标时构造右删失区间 $[L,+\infty)$ 。不删除删失样本，也不把某次检测孕周直接作为精确首次达标时间。	男胎问题 2、问题 3 的首次达标时间	保留首次达标时间的不确定性，避免把检测时点误当成真实达标时点，并充分利用尚未达标患者的信息。	已确认
4	部分字段存在条目缺失。男胎末次月经缺失 12 条、非整倍体字段空白 956 条；女胎 BMI 缺失 1 条、两列无名列全部为空，非整倍体字段大量空白。	沿用现有分类处理：问题 1—3 不使用的缺失字段保留但不进入模型；关键建模字段不做隐式填补，缺失或无法转换时停止运行；女胎两列全空无名列删除，BMI 在每个训练折内用该折中位数填补并增加“BMI 缺失”指示变量；女胎非整倍体空白按“未列出 T13/T18/T21 异常”构造为 0 标签。	男胎、女胎原始数据及各问题建模输入	避免为无关字段制造虚假数值；防止利用测试集统计量填补造成泄漏；保留 BMI 缺失本身可能携带的信息；按附件标签语义区分“空白输出”和普通数值缺失。	已确认

3 已确认规则

3.1 规则 DC-01：孕周格式统一

设原始孕周为 $w+d$ ，转换后的十进制孕周为

$$W = w + \frac{d}{7}.$$

示例：

原始孕周	十进制孕周
12w+0	12.0000
12w+3	12.4286
15w+6	15.8571

执行要求：无法匹配 w+d 形式、缺少孕周或天数超出合理范围时，不进行猜测性转换，应记录并进入异常检查。

3.2 规则 DC-02：重复检测分层处理

情形	处理方式
问题 1 的不同孕周重复检测	全部保留，使用孕妇随机截距描述同一孕妇记录间的相关性。
问题 2、3 的同孕妇同孕周重复检测	Y 染色体浓度取中位数，避免单次测量波动和重复计权。
问题 2、3 的同孕妇不同孕周检测	按十进制孕周排序，用于判断未达标—达标的时间区间。
训练、验证和测试划分	按孕妇划分，同一孕妇的记录不得跨集合。
Bootstrap	按孕妇抽样，不把同一孕妇的多条记录独立抽样。

处理后的数据单位：问题 1 仍为 1082 条纵向记录、267 名孕妇；问题 2、3 为 267 条患者级记录。

3.3 规则 DC-03：首次达到 4% 的删失区间

在完成同孕妇同孕周中位数聚合后，按十进制孕周从早到晚排列，以 Y染色体浓度 ≥ 0.04 为达标标准。

删失类型	观测情况	区间构造	当前人数
左删失	第一次检测已经达到 4%	$T \in [0, U]$ ，其中 U 为第一次检测孕周	217
区间删失	前一次未达到 4%，后一次达到 4%	$T \in [L, U]$ ，其中 L 为最后一次未达标孕周，U 为第一次达标孕周	43
右删失	所有检测均未达到 4%	$T \in [L, +\infty)$ ，其中 L 为最后一次检测孕周	7

执行要求：三类样本全部保留；不使用区间中点代替首次达标时间，不把第一次达标检测孕周视为精确事件时间。

3.4 规则 DC-04：缺失值分类处理

缺失类型	当前处理
男胎末次月经缺失 12 条	问题 1—3 直接使用检测孕周，不使用末次月经；缺失值保留但不进入模型。
男胎非整倍体字段空白 956 条	该字段不作为问题 1—3 的输入或结局，不进行填补。
问题 1—3 关键建模字段缺失	不做均值、众数等隐式填补；缺失、非有限或无法转换时停止运行并检查数据。
女胎两列全空无名列	直接删除，不进入特征集合。
女胎 BMI 缺失 1 条	在每一个外层/内层训练折内用该训练折 BMI 中位数填补；同时增加“BMI 缺失”指示变量。验证折和测试折只使用对应训练折中位数。
女胎非整倍体字段空白	按附件输出语义解释为未列出 T13、T18、T21 异常，相应标签记为 0；该标签不等同于真实临床诊断终点。

执行要求：所有填补参数只能从当前训练折计算，禁止使用全数据或测试折统计量；除上述已定义情形外，不自动填补未知字段。

4 三、第一问解答

4.1 1. 数据特征分析

项目	数据特征	对建模的影响
样本结构	男胎 1082 条检测记录对应 267 名孕妇，同一孕妇存在重复检测	记录之间并非相互独立，需要显式处理孕妇内相关性
检测孕周	范围 11—29 周，均值约 16.846 周	可以分析 Y 浓度随孕周的纵向变化，并需要考虑非线性
BMI	范围 20.703—46.875，均值约 32.289	样本整体 BMI 偏高，需检验 BMI 主效应及其与孕周的交互
Y 染色体浓度	均值 0.07719，中位数 0.07507，为 0—1 之间的比例变量	不宜直接无限外推，需要进行 logit 变换
其他变量	包括年龄、身高、IVF、读段数、比对比例和 GC 含量	可作为扩展变量检验是否提供额外统计解释量

第一问的核心任务是解释变量关系与显著性，而不是寻找最佳检测时点或构建分类器。

4.2 2. 数据预处理方案

处理步骤	具体做法	目的
数据身份核验	检查附件 SHA-256、1082 条记录、267 名孕妇及首末序号	防止输入版本发生变化
孕周转换	将 w+d 转换为 w+d/7 十进制周	支持数值计算、排序和曲线建模
重复检测	问题 1 保留全部 1082 条记录, 以孕妇代码标识重复测量	保留 Y 浓度随孕周变化的纵向信息
Y 浓度变换	将 Y 浓度截断保护到 $[10^{-6}, 1 - 10^{-6}]$ 后进行 logit 变换	适应比例变量边界并避免 0、1 导致无穷值
连续变量标准化	孕周、BMI、年龄、身高、比对比例和 GC 含量减均值后除以标准差	改善模型数值稳定性, 并使系数可按一个标准差解释
读段数处理	唯一比对读段数先取自然对数, 再标准化	缓解量级过大和右偏问题
IVF 编码	自然受孕记为 0, 其他 IVF 方式记为 1	将类别变量转换为模型可用的二元变量
缺失检查	Y 浓度等关键字段缺失时停止运行, 不做隐式填补	避免用未经确认的填补假设影响显著性

4.3 3. 模型选取及缘由

主模型选用以孕妇为随机截距的线性混合效应模型, 原因如下:

- 1. 同一孕妇的多次检测存在相关性, 普通线性回归的独立性假设不成立。
- 2. 随机截距可以描述不同孕妇 Y 浓度基础水平的个体差异。
- 3. 固定效应系数、置信区间和显著性检验便于直接回答题目要求的关系方向。
- 4. 加入孕周二次项可以描述非线性变化; 加入孕周 $\times$ BMI 交互项可以检验 BMI 是否改变孕周效应。
- 5. 第一问属于统计关系解释, 不以搜索树或黑箱预测模型作为主模型。

4.4 4. 模型及其参数介绍

基础模型为

$$\text{logit}(Y_{ij}) = \beta_0 + \beta_1 W_{ij} + \beta_2 W_{ij}^2 + \beta_3 B_{ij} + \beta_4 W_{ij} B_{ij} + u_i + \varepsilon_{ij},$$

其中:

参数	含义
β_0	所有标准化连续变量处于均值附近时的总体截距
β_1	平均孕周附近, 孕周增加一个标准差对应的 Y 浓度 logit 变化

参数	含义
β_2	孕周关系的曲率，用于判断是否偏离直线关系
β_3	相同孕周附近，BMI 增加一个标准差对应的 Y 浓度 logit 变化
β_4	孕周与 BMI 交互效应，检验 BMI 是否改变孕周增长斜率
u_i	第 i 名孕妇的随机截距， $u_i \sim N(0, \sigma_u^2)$
ε_{ij}	第 i 名孕妇第 j 次检测的记录级误差， $\varepsilon_{ij} \sim N(0, \sigma^2)$

扩展模型在基础模型上增加年龄、身高、IVF、对数唯一比对读段数、参考基因组比对比例和 GC 含量。基础模型和扩展模型均采用最大似然估计，优化方法为 L-BFGS，最多迭代 1000 次。

4.5 5. 模型训练

第一问中的 β 、随机截距方差和残差方差不是人工设定或网格搜索得到的，而是由全部 1082 条纵向记录通过最大似然估计共同求得。

1. 先按照给定参数计算每条记录的条件均值，并结合孕妇随机截距构造整组纵向观测的联合似然。
2. 对随机效应积分后得到边际对数似然；代码使用 L-BFGS 迭代寻找使对数似然最大的参数组合。
3. 基础模型和扩展模型均使用 REML=False 的最大似然估计，确保两模型的似然值可以用于似然比检验。
4. 迭代最多 1000 次；若模型未收敛，则停止接受当前结果，不能直接引用系数。
5. 参数标准误由拟合点附近的曲率信息估计；Wald 统计量、p 值及 95% 置信区间均由“系数 ÷ 标准误”及其近似分布得到。

这里不存在“训练集上调参、测试集上评分”的常规机器学习流程，因为第一问主要进行统计关系估计。若未来增加预测性验证，应按孕妇分组另做交叉验证，不能改变当前显著性检验口径。

4.6 6. 模型评分方式

评价方法	作用	判定方式
Wald 检验	判断单个固定效应系数是否显著偏离 0	结合系数、标准误、p 值和 95% 置信区间判断
AIC	比较模型拟合能力与复杂度的平衡	AIC 越低通常越优

评价方法	作用	判定方式
似然比检验	检验扩展变量作为一个整体是否增加解释量	比较基础模型与扩展模型对数似然，报告 LR、自由度和 p 值
收敛检查	确认参数优化是否成功	任一模型未收敛则不接受结果
随机效应与残差	判断孕妇间差异及记录级误差规模	比较随机截距标准差和残差标准差

第一问以参数估计和统计推断为目标，因此当前不使用训练集准确率作为评分，也不把预测交叉验证作为显著性结论的主要依据。

4.7 7. 数值结果分析

变量/检验	结果	解释
孕周一次项	$\beta=0.1668, p=3.32\times10^{-48}$	孕周与 Y 浓度显著正相关
孕周二次项	$\beta=0.0428, p=5.80\times10^{-6}$	孕周关系存在显著曲率，不能完全视为恒定斜率
BMI 主效应	$\beta=-0.0719, p=0.00250$	相近孕周下，BMI 越高，Y 浓度整体越低
孕周 $\times$ BMI	$\beta=0.00843, p=0.336$	交互不显著，不能声称不同 BMI 人群的增长速度显著不同
基础模型 AIC	836.330	基础模型比较基准
扩展模型 AIC	817.693	加入辅助变量后 AIC 降低 18.637
似然比检验	$LR=30.637, df=6, p=2.97\times10^{-5}$	年龄、身高、IVF 及测序变量整体增加统计解释量
孕妇随机截距标准差	0.434	孕妇之间的基础 Y 浓度差异明显
记录级残差标准差	0.261	同一孕妇内部仍存在检测波动和未解释误差

4.8 8. 结论解释与边界

第一问可以得出：Y 染色体浓度随孕周总体升高，并存在一定非线性；BMI 与 Y 浓度显著负相关。孕周与 BMI 交互项不显著，因此当前证据只支持“高 BMI 孕妇的 Y 浓度整体偏低”，不支持“不同 BMI 人群具有显著不同的增长速度”。扩展变量整体改善模型解释量，但不能把单项统计系数直接解释为因果作用。

该结论来自当前 267 名孕妇的内部纵向数据。样本来源单一且 BMI 分布偏高，因此不能直接外推到所有地区或临床人群。第一问的结果为问题 2、3 按 BMI 进行时点分流提供方向依据，但不能单独决定最终 BMI 切点和推荐孕周。

4.9 9. 补充

1. 若混合模型不收敛、随机效应退化或残差出现非有限值，应停止使用该结果，并考虑患者聚类稳健 GEE 作为同一解释目标下的备选实现。
2. 回退模型与混合模型的参数含义不同，必须在报告中明确区分，不能混合引用系数。
3. 如需评价第一问模型的预测外推能力，可另做按孕妇分组的交叉验证；该结果只能作为补充，不能替代 Wald 检验和似然比检验。
4. 所有系数均作用于标准化变量和 Y 浓度 logit 尺度，不能直接解释为 Y 浓度增加或减少相同数值的百分点。

5 四、第二问解答

5.1 1. 数据特征分析

本部分只描述数据现象如何阻碍“确定 BMI 分组及最佳 NIPT 时点”这一目标。

数据现象	对问题 2 的阻碍
1082 条检测记录对应 267 名孕妇	检测记录不独立，直接按记录训练或划分会重复计权并产生患者泄漏
同一孕妇仅在若干离散孕周接受检测	无法观察首次达到 4% 的精确时点，只能形成左删失、区间删失或右删失
左删失 217 人、区间删失 43 人、右删失 7 人	普通回归无法正确使用三类不完整时间信息
BMI 范围 20.703—46.875 且分布不均衡	高 BMI 尾部样本较少，切点可能受少量样本扰动，不能机械追求等人数分组
达标概率通常随孕周增加	越晚检测越容易达到 4%，但更晚发现潜在问题；“准确”与“尽早”存在冲突
题目把孕期风险分为 ≤ 12 周、13—27 周、 ≥ 28 周三级	18 周和 22 周在题面中同属中期；是否认为 18 周额外优于 22 周取决于风险解释
同孕妇同孕周重复测量存在波动	4% 附近的状况可能因测量误差改变，需要检查推荐方案是否对扰动敏感

5.2 2. 问题分析

第二问需要依次解决四类问题：

大类问题	需要回答的具体内容
首次达标时间预测	如何利用三类删失信息估计孕妇在不同孕周前达到 4% 的概率
BMI 分组	分几组、切点设在哪里、如何避免局部贪心和极小样本组
分组稳定孕周	每个 BMI 组在哪个最早整数周能够稳定满足达标可靠性要求

大类问题	需要回答的具体内容
题目风险解读	“越早越好”与“通过率越高越好”如何同时进入判优；题面三级风险和连续等待风险如何区分

这里“推荐周期越早越好”是因为检测推迟可能延后后续确认与处理；但时间早不能凌驾于检测可靠性之上。正确的判优逻辑是：先满足可靠性和稳定性，再在安全候选中选择更早、结构更简单的方案。

5.3 3. 指标定义

设第 i 名孕妇推荐孕周为 t_i ，模型预测其在该周前达到 4% 的概率为 $F_i(t_i)$ 。

指标	定义或门槛	含义
总体预测达标概率	$\text{mean}[F_i(t_i)]$	推荐时点前达到 4% 的平均预测概率
准确性风险	$R_a=1-\text{mean}[F_i(t_i)]$	推荐时点仍未达到 4% 的平均风险
平均推荐孕周	$\text{mean}(t_i)$	整体检测时间成本，越小表示越早
题面分段时间风险	按 ≤ 12 周、 $13-27$ 周、 ≥ 28 周分级	严格按照题目风险区间比较等待损失
连续时间风险	$R_t=\text{mean}[\text{clip}((t_i-13)/14,0,1)]$	敏感性分析中假设 13—27 周内部分等待损失连续增加
不稳定风险	$R_s=1-\text{重复折安全率}$	方案对重新划分数据的敏感程度
综合风险	$R=w_aR_a+w_tR_t+w_sR_s$ ，权重非负且和为 1	比较不同准确性、等待和稳定性偏好下的方案
组内平均达标安全线	至少 0.89	固定政策部署审计的组内可靠性要求
Bootstrap 安全率	至少 0.95	患者重采样后仍满足安全线的比例
重复折安全率	至少 0.90	重复划分中安全折所占比例
重复 4/4 比例	至少 0.70	100 次重复四折中四折全部安全的比例

所有门槛在测试审计前固定，不能看到测试结果后临时降低。

5.4 4. 模型与算法组件及选取缘由

模型/算法	是什么	选取缘由	解决的问题
区间删失 XGBoost-AFT	将首次达到 4% 视为生存时间，用提升树学习特征与达标时间分布的非线性关系	能直接接收左删失、区间删失和右删失上下界，并表示 BMI 等变量的非线性和交互	首次达标时间不精确、普通回归无法使用删失样本的问题
患者级嵌套交叉验证	外层测试泛化、内层调参和早停，全部按孕妇划分	防止同一孕妇跨集合和测试折参与调参	患者泄漏、过拟合和不同方案比较不公平的问题
全局 Optimal Binning	按 BMI 排序，只在相邻不同 BMI 之间建立连续分段，并比较完整候选分组	相比单棵决策树的局部贪心切分，更适合寻找整体最优、可解释的连续 BMI 区间	BMI 分几组、切点在哪儿及局部最优问题
组内最早安全周搜索	对每个候选组逐周计算预测达标概率并寻找满足安全要求的最早周	把连续概率预测转换为可执行的整数孕周建议	每组何时检测的问题
Pareto/固定方案比较	同时比较达标概率、平均孕周、稳定性和复杂度	避免只追求最早或只追求最高通过率	多目标判优问题
患者 Bootstrap、重复折与误差扰动	重采样患者、重复划分并扰动 4% 附近 Y 浓度	检查切点和时点是否由偶然样本或检测误差决定	稳定性与测量误差问题

XGBoost-AFT 只负责产生 $F_i(t)=P(T_i \leq t|x_i)$ ；Optimal Binning 负责 BMI 分组；安全周搜索负责推荐孕周。三者不能混写成一个单独算法。

5.5 5. 整体路线/算法结构

1082 条男胎检测记录

↓ 同孕妇同孕周 Y 浓度取中位数、按孕周排序

267 条患者级删失记录

↓ 外 4 折、内 3 折患者级嵌套验证

区间删失 XGBoost-AFT

↓ 得到不同孕妇、不同孕周的 OOF 达标概率

BMI 稳定排序 + 合法相邻切点

↓ 全局 Optimal Binning 比较连续分组

候选 BMI 组

↓ 逐组搜索满足可靠性的最早整数周

候选分组—时点政策

↓ 固定比较 15/18、16/18、18/22

题面风险、连续风险、Bootstrap、重复折和误差审计

↓

题面主推荐 18/22 + 连续风险敏感性方案 16/18

5.6 6. 训练方案

第二问包含三次相互衔接但目标不同的训练/优化：第一次训练达标时间分布，第二次训练 BMI 分组政策，第三次训练各组推荐时间。后两次本质上是基于冻结预测结果的决策参数优化，不再重新拟合 Y 浓度预测模型。

5.6.1 6.1 第一次训练：XGBoost-AFT 删失建模

训练目标：不猜测精确达标时间，直接利用左删失、区间删失和右删失上下界，学习每名孕妇首次达到 4% 的条件时间分布。

输入患者级数据样貌：

字段	含义	示例
孕妇代码	患者唯一标识	A001
BMI 等基线特征	检测前可以获得的特征	BMI=28.516
lower	首次达标时间下界	15.857 周
upper	首次达标时间上界	20.143 周或 $+\infty$
censoring	left、interval 或 right	interval
outer_fold	固定患者级外层折号	0—3

训练过程：

1. 由 1082 条记录构造 267 条患者级删失记录，按删失类型分层。
2. 外层 4 折中，每次约 200 名孕妇训练、66—67 名孕妇测试；外层训练集内部固定 3 折用于超参数选择和早停。
3. 对左删失、区间删失和右删失样本分别最大化 $F(U|x)$ 、 $F(U|x)-F(L|x)$ 和 $1-F(L|x)$ ，等价地最小化其负对数似然。
4. AFT 误差分布、尺度及树模型参数只使用当前外层训练数据确定；当前四个外层折均选择极值分布，尺度约为 0.733、0.781、0.778 和 0.578。
5. 每个外层模型只预测该折未见过的孕妇，最后拼接成完整 OOF 概率表。

XGBoost-AFT 并没有把删失样本“补成一个确定孕周”。它把每个删失区间转换为一条随孕周单调上升的概率曲线。

第一次训练后的数据样貌：

数据规模/字段	结果
行数	267 行，每名孕妇一行
身份与标签字段	孕妇代码、BMI、lower、upper、删失类型、外层折号
概率时间网格	10.000—25.000 周，每隔 1/7 周计算一次

数据规模/字段	结果
概率字段数	106 列，记为 p_10.000 至 p_25.000
单元格含义	$p_t = P(T \leq t x)$ ，表示在 t 周前达到 4% 的 OOF 预测概率

例如 A001 的删失区间为 [15.857,20.143]，其 OOF 达标概率从 10 周的 0.6936 上升到 16 周的 0.9305、18 周的 0.9620 和 22 周的 0.9902。该概率表是后两次训练共同使用的冻结输入。

5.6.2 6.2 第二次训练：全局 Optimal Binning 确定 BMI 组数与切点

训练目标：在 BMI 连续、有序且每组样本量可靠的约束下，确定分几组以及切点在哪里，使各组存在足够早且安全的推荐孕周。

最终采用全局有序分组搜索：

1. 将 267 名孕妇按 BMI 稳定排序，只允许在相邻不同 BMI 值之间切分。
2. 每个开发折搜索 $1.\text{floor}(n_{\text{开发}}/30)$ 个连续组；约 200 名开发患者时覆盖 1—6 组，全样本理论上最多 8 组。
3. 对每个候选区间读取 AFT 的 OOF 周概率，寻找单侧 90% 置信下限达到 0.95 的最早整数孕周。
4. 在满足组规模和可靠性约束的完整分组中，通过动态规划最小化患者加权平均推荐孕周。
5. 在最优开发平均孕周 0.25 周以内优先选择组数更少的结构，再到完全留出的外层测试患者评价。

四个外折中一组和两组各被选择 2 次，3 组及以上均未胜出；平均测试孕周 18.949 周、平均测试达标概率 0.9556，均值安全 4/4 折、保守 LCB 安全 3/4 折。因此数据支持简单分组结构，最终为部署可解释性采用两组政策。

第二次训练的最终分组：

最终 BMI 范围	人数	占比
BMI<34.357	215	80.5%
BMI≥34.357	52	19.5%

固定切点网格审计表明，在每组至少 30 人并完成 4 个外折的条件下，29.75—34.50 为均值与 LCB 均 4/4 安全的平台；算法切点 34.357 位于该平台内。

5.6.3 6.3 第三次训练：最优推荐时间与安全裕量校准

训练目标：在第二次训练固定的两组结构下，为低 BMI 组和高 BMI 组选择可执行的推荐孕周，处理“越早越好”和“达标概率越高越好”的冲突。

使用 100 次重复四折和患者 Bootstrap 比较最终可执行方案：

最终比较方案	Bootstrap 安全率	重复折安全率	重复 4/4 比例	定位
15/18	0.9812	0.83	0.41	重复划分不稳定，淘汰
16/18	0.9976	0.94	0.77	连续等待风险下的效率折中方案
18/22	1.0000	1.00	1.00	题面三级风险下的主推荐

第三次训练最终没有只输出一个“数学最早周”，而是输出两层政策：题面把 18 周和 22 周都视为中期，因此主推荐选择准确性和稳定性更高的 18/22；如果额外假定 13—27 周内部等待损失连续增加，则保留 16/18 作为风险权重敏感性方案。

5.7 7. 验证方案

验证层	做法	作用
外层 4 折	按删失类型分层，每名孕妇仅出现于一个测试折	生成未参与该折训练的患者级 OOF 概率
内层 3 折	仅在外层训练集内调参和早停	隔离模型选择与外层评价
固定政策回放	在同一批冻结预测上比较 15/18、16/18 和 18/22	保证不同政策使用相同预测基础
患者 Bootstrap	以孕妇为单位重采样，不独立抽取检测记录	估计组内可靠性和方案排序的抽样波动
100 次重复四折	改变患者折分后重新检查各折安全性	评价方案对数据划分的稳定性
测量误差敏感性	根据同孕妇同孕周重复检测估计误差并扰动 Y 浓度	检查 4% 附近状态改变是否推翻方案排序

上述属于内部验证，不是来自新医院或新时间段的外部测试。最终切点和固定政策经过当前数据开发，不能把内部回放结果表述为完全独立的无偏临床成绩。

5.8 8. 结论对比

方案	平均推荐孕周	总体达标概率	Bootstrap 安全率	重复折安全率	重复 4/4 比例	判定
15/18	15.584	0.9102	0.9812	0.83	0.41	过早且重复折不稳定，淘汰
16/18	16.390	0.9244	0.9976	0.94	0.77	满足内部稳定门槛，作为连续等待风险敏感性方案
18/22	18.779	0.9555	1.0000	1.00	1.00	题面三级风险下准确性与稳定性最好，作为主推荐

15/18 虽然最早，但重复折安全率和 4/4 比例未达门槛；16/18 在效率与可靠性之间折中；18/22 最晚，但三套方案均处于题目规定的中期风险区间，因此题面口径下优先选择其更高的达标概率和稳定性。

5.9 9. 最终结果

题面三级风险主推荐：

BMI 范围	人数	推荐 NIPT 时点	适用口径
BMI<34.357	215	第 18 周	题面三级风险；准确性与稳定性优先
BMI≥34.357	52	第 22 周	题面三级风险；准确性与稳定性优先

连续等待风险敏感性方案：

BMI 范围	人数	推荐 NIPT 时点	适用口径
BMI<34.357	215	第 16 周	假定 13—27 周内等待损失连续增加
BMI≥34.357	52	第 18 周	假定 13—27 周内等待损失连续增加

主推荐的总体预测达标概率为 0.9555。这里的达标概率是 Y 染色体浓度达到 4% 的概率，不是胎儿异常诊断准确率。

5.10 10. 补充

- 34.357 是当前数据和目标函数下的算法切点，不是通用医学 BMI 诊断界值；报告中可写为 34.36。
- 每组至少 30 人的约束用于防止统计上极不稳定的小组，不要求不同 BMI 组人数相等；最终两组为 215 人和 52 人。
- 当 $w_s=0$ 时，16/18 仅在准确性权重约 0.8022—0.8461 范围内最优，因此它依赖风险偏好，不能替代题面主答案。
- 结果来自单一数据源和内部验证，高 BMI 尾部样本有限，尚无独立医院数据验证。
- 推荐用于数学建模和研究性检测分流，不构成临床诊断或处置意见。

6 五、第三问解答

6.1 1. 数据特征分析

沿用前述 267 名孕妇的患者级删失数据、重复检测聚合、孕周转换、患者级划分和删失区间构造规则，不再重复展开。

新增使用年龄、身高、体重、IVF、孕次和产次等检测前因素。当前主要障碍为：变量增加后过拟合风险上升；BMI、身高和体重之间存在相关性；高 BMI 尾部样本较少；平均

达标概率可能掩盖组内高风险个体；多因素概率最终仍需压缩成可执行的 BMI 分组；测量误差可能改变 4% 附近样本的达标状态。

6.2 2. 问题分析

大类问题	具体任务
多因素达标建模	综合年龄、身高、体重、BMI、IVF、孕次和产次估计不同孕周前达到 4% 的概率
分组结构优化	根据多因素概率确定合理的 BMI 组数及连续切点
组内安全周期	为每个 BMI 组寻找满足可靠性要求的最早整数孕周
组内差异控制	同时考虑平均达标概率、组内个体差异和样本量
结果稳定性	检查组数、切点和时点是否随折分或患者重采样发生明显变化
测量误差处理	检查 Y 浓度扰动是否推翻推荐政策
部署简化	将不稳定的小数切点转化为便于解释和执行的方案

目标不是机械增加组数，而是在综合相关因素后，寻找可靠性、检测时间、稳定性和可解释性之间的平衡。

6.3 3. 指标定义

6.3.1 3.1 维持定义

总体预测达标概率、准确性风险、平均推荐孕周、题面分段时间风险、连续时间风险、不稳定风险、综合风险、Bootstrap 安全率、重复折安全率和测量误差状态改变率沿用前述定义。

6.3.2 3.2 新增定义

设某一 BMI 组在孕周 t 的平均预测达标概率为 $\bar{p}_g(t)$ 、组内标准差为 $s_g(t)$ 、人数为 n_g ，定义单侧保守下界：

$$LCB_g(t) = \bar{p}_g(t) - 1.645 \frac{s_g(t)}{\sqrt{n_g}}.$$

新增指标如下：

指标	定义	作用
组内保守下界	LCB_g(t)	同时反映组内均值、个体差异和样本量
均值安全折数	外层测试折中最低平均达标概率达到安全线的折数	评价平均意义下的跨折可靠性
保守下限安全折数	外层测试折中最低 LCB 达到安全线的折数	评价更严格的跨折可靠性
切点 Bootstrap 区间	切点 Bootstrap 分布的 2.5% 和 97.5% 分位数	评价精确切点的抽样稳定性
组数选择稳定率	某组数在 Bootstrap 中被选择的次数除以总次数	评价分组结构是否反复出现

6.3.3 3.3 变更定义

安全周由主要依据组内平均达标概率，调整为优先依据保守下界：

$$t_g^* = \min\{t : LCB_g(t) \geq q\}.$$

开发安全裕量取 q=0.95。判优顺序调整为：先保证候选可行和保守可靠，再比较均值可靠性与平均推荐孕周；性能接近时优先采用组数更少、切点更稳定且更容易解释的结构。

6.4 4. 模型与算法组件及选取缘由

模型或算法	是什么	选取缘由	解决的问题
多因素 XGBoost-AFT	在删失时间模型中加入 BMI、年龄、身高、体重、IVF、孕次和产次	能处理删失并表示多因素非线性关系	生成综合相关因素后的达标概率
有序动态规划	按 BMI 排序，在连续 BMI 区间中组合可行分段	固定约束下可比较完整切点组合，避免局部贪心	确定连续 BMI 分组及切点
保守下界安全周搜索	根据 LCB 确定组内最早安全孕周	防止平均值掩盖组内高风险个体	确定稳定检测周期
嵌套政策选择	每个外层训练折内部重新选择分组和时点	防止外层测试结果参与选参	评价整套优化流程的泛化能力
患者 Bootstrap	以孕妇为单位重采样并重新执行政策审计	检查切点和政策是否由少量患者决定	评价抽样稳定性
测量误差模拟	按重复检测估计的误差扰动 Y 浓度	检查 4% 附近状态变化	评价最终政策对测量误差的敏感程度

6.5 5. 整体路线/算法结构

患者级删失数据

↓ 加入年龄、身高、体重、BMI、IVF、孕次和产次

多因素 XGBoost-AFT

↓ 生成不同孕周前达到 4% 的 OOF 概率

BMI 稳定排序

↓ 有序动态规划搜索连续 BMI 分组

保守下界安全周搜索

↓ 外层训练折内部选择分组、切点和时点

嵌套外层审计

↓ Bootstrap 切点与政策稳定性分析

测量误差模拟

↓ 简化切点并形成可执行政策

6.6 6. 训练方案

6.6.1 6.1 多因素达标概率训练

输入特征为：

$$x_i = (BMI, Age, Height, Weight, IVF, Gravidity, Parity).$$

输出为：

$$F_i(t) = P(T_i \leq t \mid x_i).$$

删失似然、患者级外 4 折、内 3 折和 OOF 概率生成方式沿用前述方案。输出仍为 267 行患者级概率曲线，后续优化读取冻结概率，不重新拟合 AFT 模型。

6.6.2 6.2 BMI 分组结构训练

将孕妇按 BMI 稳定排序，只允许在相邻不同 BMI 值之间设置切点。对每个候选 BMI 区间，计算不同孕周下的组内均值和 LCB，寻找满足 $LCB \geq 0.95$ 的最早孕周；不存在安全孕周的区间记为不可行。

有序动态规划组合多个可行区间，并在给定实验约束下最小化：

$$\sum_g n_g t_g,$$

即最小化患者加权平均推荐孕周。每个开发折搜索 $1.\text{floor}(\text{n开发}/30)$ 个组；约 200 名开发患者时实际覆盖 1—6 组。

6.6.3 6.3 推荐时点与部署政策训练

在每个外层训练折内完成分组、切点和时点选择；以开发平均孕周为效率指标，在相差不超过 0.25 周的近优方案中优先选择更简单的结构。冻结后应用到该折测试孕妇，外层测试结果不参与当前折的选参。

全样本有序分组得到切点 34.357；固定切点网格的 4/4 安全平台为 29.75—34.50，因此采用 34.357 作为最终数据切点。

6.7 7. 验证方案

患者级外层 4 折、内层 3 折、患者 Bootstrap 和测量误差模拟沿用前述验证原则。

无外层选参审计中，每个外层折只依据该折训练数据选择分组和时点，得到：平均测试孕周 18.949、平均测试达标概率 0.9556、均值安全 4/4 折、保守下限安全 3/4 折。

6.8 8. 结论对比

外层测试折	开发集选择组数	开发集切点	开发集推荐孕周	测试平均孕周	测试总体达标概率	测试审计最低均值	测试审计最低 LCB	均值安全	LCB 安全
1	1	无	19	19.000	0.9598	0.9128	0.8938	是	否
2	2	35.171	19/23	19.478	0.9573	0.9523	0.9452	是	是
3	1	无	19	19.000	0.9583	0.9434	0.9274	是	是
4	2	32.454	17/20	18.318	0.9469	0.9386	0.9283	是	是
汇总	1 组和 2 组各 2 折	—	—	18.949	0.9556	—	—	4/4 折	3/4 折

全部可行组数搜索中，一组和两组各被选择 2/4 折，3 组及以上均未胜出。各折测试总体达标概率为 0.9469—0.9598，四折均值安全，三个外折同时满足保守 LCB 安全。综合可靠性、平均推荐孕周和执行可解释性，最终采用两组政策；该结论表示简单结构具有稳定优势，不表示两组在每次数据划分中都是唯一最优。

6.9 9. 最终结果

BMI 范围	人数	推荐 NIPT 时点
BMI<34.357	215	第 18 周
BMI≥34.357	52	第 22 周

指标	数值
平均推荐孕周	18.949
总体预测达标概率	0.9556

指标	数值
均值安全折数	4/4
保守 LCB 安全折数	3/4

6.10 10. 补充

1. 算法切点 34.357 位于 29.75—34.50 的 4/4 安全网格平台内；它是当前数据与目标函数共同确定的切点，不是通用医学 BMI 诊断界值。
2. 测量误差标准差约为 0.003716，最终政策下平均状态改变率约为 2.72%，没有推翻 18/22 政策。
3. 保守 LCB 为 3/4 折安全，因此论文中应将结果表述为内部稳健推荐，而非绝对安全结论。
4. 当前结果属于内部验证，尚无独立医院或新时间段数据验证。

7 六、第四问解答

7.1 1. 数据特征分析

女胎数据包含 605 条检测记录、147 名孕妇和 31 个原始字段，平均每名孕妇约 4.12 条记录，最多 9 条。标签来自附件 AB 列“染色体的非整倍体”，将组合字符串拆为三个非互斥二元标签。

标签	阳性记录数	阳性孕妇数	数据障碍
T13	23	18	阳性较少，指标波动较大
T18	46	30	三类中样本相对最多，但仍明显不平衡
T21	13	12	极少样本，最容易出现不稳定和过拟合
任一异常	67	44	适合总体风险排序，但不能替代染色体特异判定
未列出异常	538	—	占大多数，普通准确率会产生误导

附件存在 T13T18、T13T21 和 T18T21 等组合标签，因此不能建成互斥多分类。AE 列“胎儿是否健康”605 条均为“是”，没有可用于监督学习的真实临床结局；当前只能复现 AB 列筛查标签，不能声称诊断真实胎儿疾病。

同一孕妇存在重复检测，若随机拆分记录会导致同一孕妇同时进入训练集和测试集。BMI 缺失 1 条，两列无名列全部为空；标签严重不平衡，筛查任务需要优先控制漏检，同时承担较多假阳性和复测负担。

7.2 2. 问题分析

大类问题	具体任务
多标签异常判定	同时输出 T13、T18 和 T21 概率及非互斥标签
类别不平衡	防止模型只预测大量阴性记录而获得虚高准确率
重复检测	保证同一孕妇全部记录始终位于同一数据折，并限制多次检测孕妇的总权重
概率与阈值	将连续风险概率转化为染色体特异阳性/阴性判定
概率校准	使模型分数尽可能具有概率解释
不确定记录	对阈值附近结果设置复测区，而不是强制二分类
测序质量	识别读段、比对比例、GC 等质量极端记录
方法对照	与固定 Z 值规则和训练型 Z 值规则公平比较
结论边界	明确输出属于附件筛查标签复现和研究性分流

7.3 3. 指标定义

7.3.1 3.1 维持定义

患者级外层测试、内层 OOF 选参、患者 Bootstrap、输入哈希固定和测试折不参与参数选择等验证定义沿用前述原则。模型稳定性继续通过不同外层折和患者重采样评价，不按检测记录独立抽样。

7.3.2 3.2 新增定义

设 TP、TN、FP、FN 分别为真阳性、真阴性、假阳性和假阴性。

指标	定义	作用
灵敏度	$TP/(TP+FN)$	衡量阳性标签被检出的比例，筛查任务优先关注
特异度	$TN/(TN+FP)$	衡量阴性记录被正确排除的比例
阳性预测值 PPV	$TP/(TP+FP)$	衡量模型阳性中附件标签阳性的比例
阴性预测值 NPV	$TN/(TN+FN)$	衡量模型阴性中附件标签阴性的比例
F1	精确率和召回率的调和平均	平衡漏检和误报
F2	对召回率赋予更高权重的 F 分数	符合筛查阶段漏检代价较高的取向

指标	定义	作用
ROC-AUC	灵敏度—假阳性率曲线下面积	衡量概率排序能力，但不单独判优
PR-AUC	精确率—召回率曲线下面积	类别不平衡下的主排序指标
Brier 分数	$\text{mean}[(p-y)^2]$	衡量概率误差，越小越好
复测率	被标记为阈值附近或质量异常的记录比例	衡量不确定性处理带来的执行成本
患者 Bootstrap 区间	以孕妇为单位有放回抽样得到的指标分位数区间	衡量小样本和稀有阳性造成的不确定性

7.3.3 3.3 变更定义

任务输出由“首次达标时间和推荐孕周”变更为“染色体异常概率、多标签判定和复测状态”。主判优指标变更为宏平均 PR-AUC 及稀有标签灵敏度；阈值选择优先保证灵敏度不低于 85%，再最大化特异度，并以 F2 处理并列。普通准确率不作为主指标。

任一异常概率采用三个染色体概率并集：

$$p_i(any) = 1 - \prod_{c \in \{13,18,21\}} (1 - p_{ic}).$$

该概率用于总体风险排序；染色体特异性标签仍由三个独立阈值决定。

7.4 4. 模型与算法组件及选取缘由

模型或算法	是什么	选取缘由	解决的问题
三个代价敏感 XGBoost 分类器	分别预测 T13、T18 和 T21 概率	能表示 Z 值、GC、读段质量和孕妇特征的非线性交互	多标签概率筛查
患者等权	同一孕妇每条记录权重与其记录数倒数成正比	防止多次检测孕妇支配损失	重复检测计权偏差
正类权重	每个训练折中以阴性数/阳性数提高正类损失权重	缓解阳性稀少导致的全阴性倾向	类别不平衡
Platt 校准	用内层 OOF 分数拟合单变量 sigmoid 概率映射	改善模型分数的概率解释	概率校准
灵敏度优先阈值搜索	在内层 OOF 概率的全部候选阈值中按固定规则选择	阈值不读取外层测试标签	概率到判定的转换
阈值不确定带	根据预测概率到阈值的距离确定复测区	避免对边界记录强制二分	不确定记录处理

模型或算法	是什么	选取缘由	解决的问题
训练折质量分位数	根据读段、比对、重复、过滤和 GC 分布标记质量极端	不使用测试折统计量设定质量线	低质量检测识别
Z 值规则对照	固定 $ Z \geq 3$ 及训练折内搜索的 Z 阈值	提供简单透明的传统基准	判断复杂模型是否提供额外筛查能力

7.5 5. 整体路线/算法结构

605 条女胎检测记录

↓ 标签拆分、孕周转换、缺失和泄漏字段处理

T13/T18/T21 三个非互斥标签

↓ 患者级外 4 折、内 3 折

三个代价敏感 XGBoost 分类器

↓ 内层 OOF 参数选择与 Platt 概率校准

染色体特异概率

↓ 灵敏度优先阈值搜索

T13/T18/T21 多标签判定

↓ 概率并集形成任一异常风险

阈值不确定带 + 测序质量规则

↓

筛查阳性 / 筛查阴性 / 阈值附近复测 / 质量异常重抽

↓

Z 值规则对照 + 患者 Bootstrap 稳定性评价

7.6 6. 训练方案

7.6.1 6.1 多标签概率模型训练

对每个染色体 $c \in \{13, 18, 21\}$ 分别训练分类器：

$$p_{ic} = P(y_{ic} = 1 \mid x_i).$$

输入包括目标染色体及 X 染色体 Z 值、X 染色体浓度、读段数量与比例、GC 含量、年龄、身高、体重、BMI、孕周、IVF、孕次、产次和抽血次数；同时构造绝对 Z 值、最大绝对 Z 值、Z 值间差异、唯一比对读段占比、GC 偏离量及 BMI 缺失指示。

每个训练折内计算患者等权 v_i 和正类权重 α_c ，优化带权二元对数损失：

$$L_c = - \sum_i v_i [\alpha_c y_{ic} \log p_{ic} + (1 - y_{ic}) \log(1 - p_{ic})] + \Omega(f_c).$$

内层候选配置比较树深、学习率、采样率、正则化和迭代轮数，主评分为 PR-AUC，辅助参考 F2 和概率误差。

7.6.2 6.2 概率校准与阈值训练

用完整内层 OOF 原始概率拟合 Platt 校准器，再作用于外层测试原始概率。内层 OOF 阳性少于 8 条、阴性少于 20 条或校准器数值失败时，回退到原始 XGBoost 概率。

对每个染色体枚举相邻唯一概率的中点及两个端点作为候选阈值。阳性样本充足时，先保留灵敏度不低于 85% 的阈值，再选择特异度最高者；并列时依次选择 F2 更高和阈值更高者。样本不足或无可行阈值时，改为优先最大化 F2。

7.6.3 6.3 复测与最终分流规则训练

定义阈值距离 $d_{ic}=|p_{ic}-t_c|$ ，不确定带宽取训练 OOF 距离的 15% 经验分位数且不超过 0.15。若任一染色体位于不确定带，则建议复测。

测序质量规则只使用训练折分位数：六项质量指标中至少两项越界，或总/唯一读段数低于训练折 0.5% 分位点时，标记质量异常并建议重抽复检。最终分流优先级为质量异常、阈值附近、筛查阳性、筛查阴性。

7.7 7. 验证方案

外层 4 折按孕妇分组，每折测试 36—37 名孕妇、151—152 条记录；患者重叠数为 0。内层 3 折完成特征处理、参数选择、校准、阈值和复测带宽确定。分折使用患者级多标签平衡搜索，使每个外层测试折均包含 T13、T18 和 T21 阳性孕妇。

每个染色体分别与固定 $|Z|\geq 3$ 规则和训练型 Z 阈值比较。患者级 Bootstrap 重复 2000 次，报告灵敏度、特异度、PR-AUC、ROC-AUC、F2 和 Brier 分数的 95% 区间。若稀有标签长期零召回、性能低于 Z 值基准、Bootstrap 下限接近随机或复测负担失控，则不得宣称主模型有效。

7.8 8. 结论对比

标签	方法	灵敏度	特异度	PR-AUC	ROC-AUC	F2
T13	XGBoost	0.8869	0.3107	0.1965	0.7602	0.2037
T13	固定 $ Z \geq 3$	0.0417	0.9673	0.0672	0.4827	0.0403
T18	XGBoost	0.8674	0.5184	0.4246	0.8193	0.4047
T18	固定 $ Z \geq 3$	0.0000	0.9409	0.0883	0.5172	0.0000
T21	XGBoost	0.8542	0.3022	0.0444	0.5178	0.1171
T21	固定 $ Z \geq 3$	0.0000	0.9966	0.0473	0.4851	0.0000

XGBoost 明显提高 T13 和 T18 的灵敏度及 PR-AUC，但牺牲特异度和阳性预测值。T21 虽然达到较高灵敏度，其 PR-AUC 仅 0.0444、ROC-AUC 约 0.518，排序能力仍然有限，不能表述为稳定识别。

任一异常概率并集的描述性 PR-AUC 为 0.4458，直接任一异常分类器为 0.4264；四个外层折均依据各自训练 OOF 结果选择概率并集。

7.9 9. 最终结果

任一异常概率层的内部外层结果为：灵敏度 0.8337、特异度 0.4093、阳性预测值 0.1525、F2 为 0.4349、ROC-AUC 为 0.7756、PR-AUC 为 0.4622、Brier 分数为 0.0831。最终决策层将 605 条记录聚合为 147 名孕妇，并执行患者级三分流。

最终分流	患者数	含义
直接阳性	40	达到患者级阳性阈值且重复检测满足一致性要求
建议复测	71	概率处于复测区、质量异常或仅有 T21 单独阳性信号
筛查阴性	36	未达到直接阳性或复测条件

患者级直接阳性灵敏度为 0.500、特异度为 0.825、PPV 为 0.550；直接阳性与复测合并后的覆盖灵敏度为 0.909，复测率为 0.483，筛查阴性中有 4 名孕妇曾出现附件异常标签。

2000 次患者 Bootstrap 中，任一异常灵敏度 95% 区间约为 0.737—0.926、特异度约为 0.355—0.462、PR-AUC 约为 0.311—0.569，说明当前样本下仍存在较大不确定性。

7.10 10. 补充

1. 筛查阳性不等于临床确诊，应结合遗传咨询、羊水穿刺、核型分析或其他诊断性检查。
2. AB 列是当前需要复现的附件筛查标签；AE 列缺乏真实阴性/阳性变化，不能验证真实疾病诊断能力。
3. 患者级三分流提高了直接阳性的特异度和 PPV，但需要 48.3% 的复测率，并仍存在 4 名附件异常标签未覆盖者。
4. T21 只有 13 条阳性记录，Bootstrap 区间宽，当前证据不足以宣称稳定预测。
5. 患者级三分流采用复测率不超过 55% 的开发约束，外层汇总复测率为 48.3%；该负担必须与覆盖灵敏度 0.909 同时报告。
6. 当前只有内部嵌套患者级验证，尚无独立医院、真实核型或出生结局外部验证。
7. 最终方法仅用于数学建模和研究性筛查分流，不构成临床诊断或处置意见。

8 七、补充验证与最终诊断

8.1 1. 全部可行组数的嵌套验证

每个外折将测试孕妇完全留出，在开发患者内部进行 3 折 OOF AFT 训练。候选组数取 $1.\text{floor}(n_{\text{开发}}/30)$ ；约 200 名开发患者时搜索 1—6 组，全样本理论上最多 8 组。各外折

的提升轮数仅由对应开发集内层早停确定，依次为 150/64/853/113。

BMI 按数值稳定排序，只允许在相邻不同 BMI 之间切分。每个区间选择单侧 90% 置信下限达到 0.95 的最早整数孕周，通过动态规划最小化患者加权平均推荐孕周；在最优值 0.25 周以内选择组数更少的结构。

指标	结果
选择 1 组	2/4 折
选择 2 组	2/4 折
选择 3 组及以上	0/4 折
平均测试推荐孕周	18.949 周
平均测试达标概率	0.9556
均值安全折数	4/4
保守 LCB 安全折数	3/4

最终采用两组可执行政策：BMI<34.357 第 18 周、BMI≥34.357 第 22 周。固定切点网格中，29.75—34.50 为均值与 LCB 均 4/4 安全的平台，算法切点 34.357 位于平台内。

8.2 2. 患者级筛查三分流

- 605 条女胎记录聚合为 147 名孕妇；43 名孕妇的重复记录标签不一致，因此患者目标严格定义为“是否曾出现附件筛查异常标签”，不解释为真实疾病。
- 每个外折只用其余三个外折的 OOF 患者选择概率阳性阈值和复测下阈值；四折均选择直接阳性阈值0.30/复测下阈值0.15。
- 患者级结果为直接阳性 40 人、复测 71 人、阴性 36 人；直接阳性特异度 0.825、PPV 0.550，三分流覆盖灵敏度 0.909，复测率 0.483，阴性中仍有 4 名曾出现附件异常标签者。
- T21 单独阳性信号全部进入复测，不直接判为稳定阳性。该方案用于附件筛查标签的研究性分流，不构成临床诊断。

8.3 3. 推荐时点策略敏感性

- 5151 个准确性一等待一不稳定风险权重点中，15/18、16/18、18/22 的胜出比例分别为 27.9%、34.5%、37.6%；该比例是离散网格面积近似，不是先验概率。
- 125 套稳定门槛组合中，三套方案的可行率分别为 0%、12.8% 和 100%，说明 18/22 对稳定门槛最稳健。
- 严格按每组至少 30 人且完成 4 个外折的固定切点表，4/4 均值与 LCB 安全平台为 29.75—34.50；算法切点 34.357 位于平台内。

8.4 4. 主混合模型诊断

- 主模型随机截距方差 0.1884，未发生随机效应退化；随机截距标准差约 0.4153。

- $|\text{标准化残差}| > 3$ 的记录比例为 1.386%，残差与孕周相关约为 0，残差与拟合值相关为 0.160，提示仍存在轻度结构性误差。
- 200 次患者级 Bootstrap 全部收敛。孕周线性项区间 [0.1357, 0.1945]、二次项 [0.0236, 0.0608]；BMI 项 [-0.1292, -0.00054]；孕周 $\times$ BMI 交互 [-0.02195, 0.02899]。
- 结果继续支持孕周正向、BMI 负向关联；交互项区间跨 0，不支持稳定交互效应。